Universidad del Valle de Guatemala
Facultad de Ingeniería
Inteligencia Artificial

Laboratorio 3

Dilary Cruz - 231010

June Herrera - 231038

Andrés Mazariegos - 21749

Universidad del Valle de Guatemala
Facultad de Ingeniería
Inteligencia Artificial

Ejercicio 1

Análisis de desempeño

El modelo obtuvo una accuracy del 97.78% en el conjunto de prueba métricas, lo que indica una excelente capacidad de generalización.

El classification report muestra valores altos de precision, recall y F1-score para todas las clases, con ligeras disminuciones en el dígito 8 (recall = 0.91), lo cual es consistente con las confusiones observadas en la matriz.

La matriz de confusión evidencia que la mayoría de las predicciones se concentran en la diagonal principal, lo que confirma el buen desempeño del modelo.

Los errores observados corresponden principalmente a dígitos visualmente similares, como:

- 8 confundido con 1
- 6 confundido con 8
- 9 confundido con 7

Universidad del Valle de Guatemala

Facultad de Ingeniería

Inteligencia Artificial

Matriz de Confusión

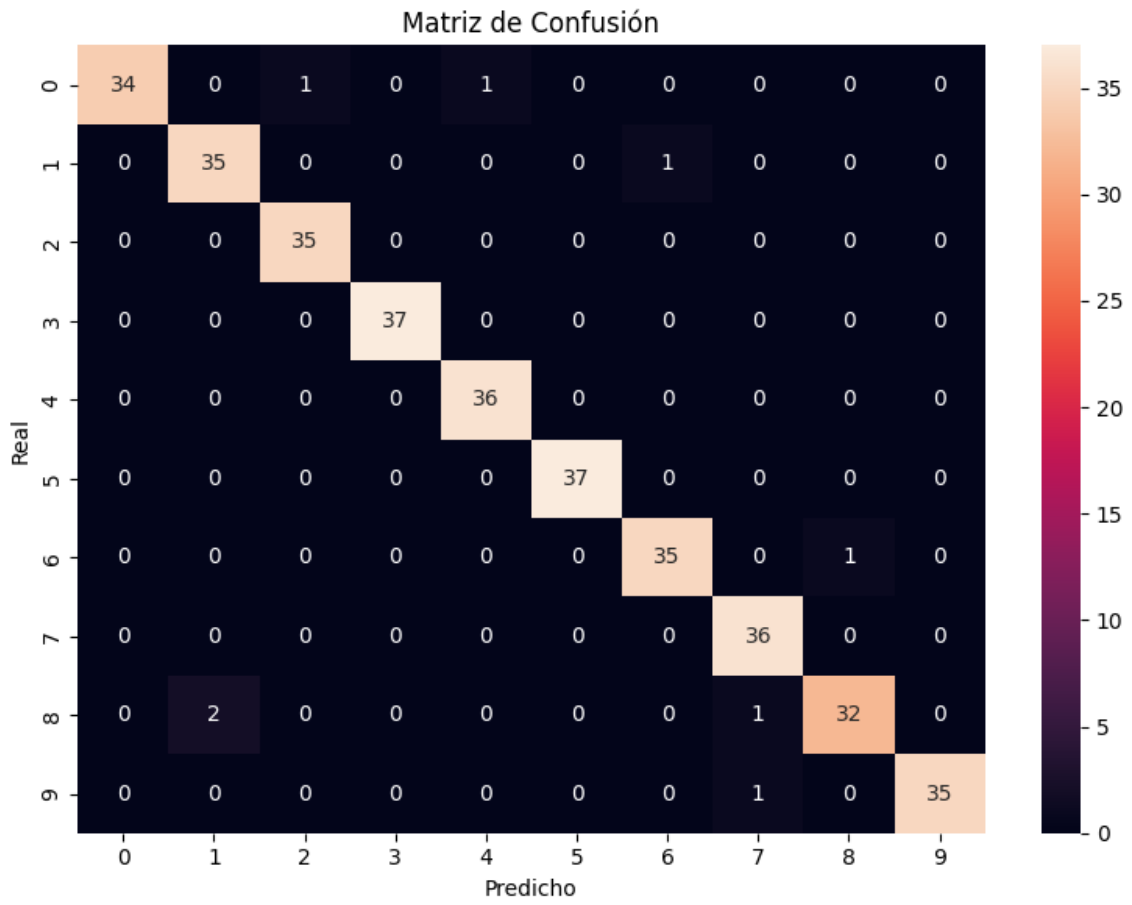

5 Ejemplos mal clasificadas

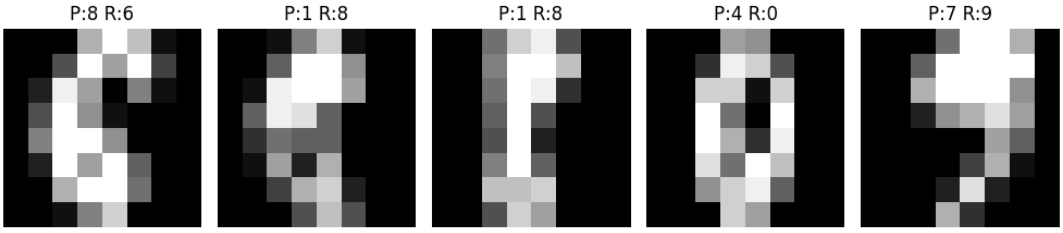

Universidad del Valle de Guatemala

Facultad de Ingeniería

Inteligencia Artificial

5 ejemplos bien clasificadas

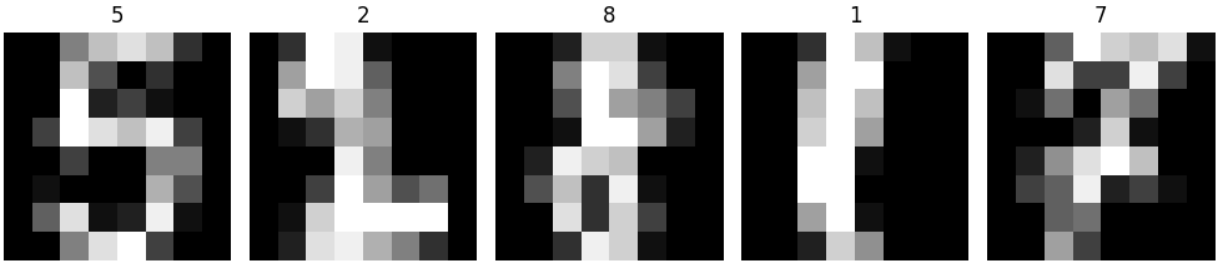

Metricas

```
Test Accuracy: 0.9778

Classification Report:
              precision    recall  f1-score   support

           0       1.00      0.94      0.97        36
           1       0.95      0.97      0.96        36
           2       0.97      1.00      0.99        35
           3       1.00      1.00      1.00        37
           4       0.97      1.00      0.99        36
           5       1.00      1.00      1.00        37
           6       0.97      0.97      0.97        36
           7       0.95      1.00      0.97        36
           8       0.97      0.91      0.94        35
           9       1.00      0.97      0.99        36

    accuracy                           0.98       360
   macro avg       0.98      0.98      0.98       360
weighted avg       0.98      0.98      0.98       360
```

Ejercicio 2

El modelo obtuvo un RMSE de 0.5358 en el conjunto de prueba, junto con un MSE de 0.2870 y un MAE de 0.3733, lo que indica una adecuada capacidad de generalización en la predicción de precios de vivienda.

Las métricas de error muestran valores moderados y consistentes entre sí, lo que sugiere que el modelo no presenta errores extremos significativos y mantiene una predicción estable en la mayoría de las observaciones.

El gráfico de dispersión (Predicciones vs Valores Reales) evidencia una fuerte correlación lineal positiva, ya que la mayoría de los puntos se concentran alrededor de la diagonal imaginaria, lo que confirma un buen ajuste del modelo a los datos. Los mayores errores observados corresponden principalmente a:

• Viviendas con precios elevados (cercanos al límite superior del dataset), donde la dispersión es mayor.

• Algunas observaciones intermedias donde las variables socioeconómicas pueden presentar relaciones no lineales más complejas.

El modelo demuestra un desempeño sólido para una arquitectura fully connected simple, validando la efectividad del proceso de estandarización y la elección de hiperparámetros.

Arquitectura del modelo

Se diseñó una red neuronal fully connected compuesta por:

- Capa de entrada: 8 características.
- Primera capa oculta: 64 neuronas (ReLU).
- Segunda capa oculta: 32 neuronas (ReLU).
- Tercera capa oculta: 16 neuronas (ReLU).
- Capa de salida: 1 neurona (activación lineal implícita).

Justificación

Se utilizaron tres capas ocultas debido a la complejidad de las relaciones no lineales entre variables socioeconómicas y precios de vivienda.

La reducción progresiva 64 → 32 → 16 permite una extracción jerárquica de características.

La función ReLU fue elegida por su eficiencia computacional y su capacidad para evitar el problema del gradiente desvanecido.

La capa de salida no utiliza función de activación, ya que en regresión se requiere predecir valores continuos.

Función de pérdida y optimización

$$MSE(MeanSquaredError)$$

Esta función penaliza más fuertemente los errores grandes y es ampliamente utilizada en problemas de regresión.

Como optimizador se empleó Adam, con learning rate 0.001, debido a su capacidad de adaptación automática del paso de aprendizaje y su rápida convergencia.

Se utilizaron los siguientes hiperparámetros:

- Learning rate: 0.001
- Batch size: 32
- Epochs: 50
- Validation split: 0.2

Estos valores permitieron un entrenamiento estable sin evidencia de sobreajuste significativo.

Evaluación del modelo

El modelo fue evaluado utilizando las siguientes métricas:

- MSE: 0.2870
- MAE: 0.3733
- RMSE: 0.5358

El RMSE indica que el error promedio de predicción es aproximadamente 0.53 unidades en la escala del precio medio de vivienda.

El scatter plot de Predicciones vs Valores Reales muestra una fuerte correlación lineal, evidenciando una adecuada capacidad de generalización del modelo.

Finalmente, se generaron tres nuevas predicciones utilizando observaciones no vistas durante el entrenamiento, confirmando el funcionamiento correcto del modelo.

Universidad del Valle de Guatemala

Facultad de Ingeniería

Inteligencia Artificial

Scatter plot

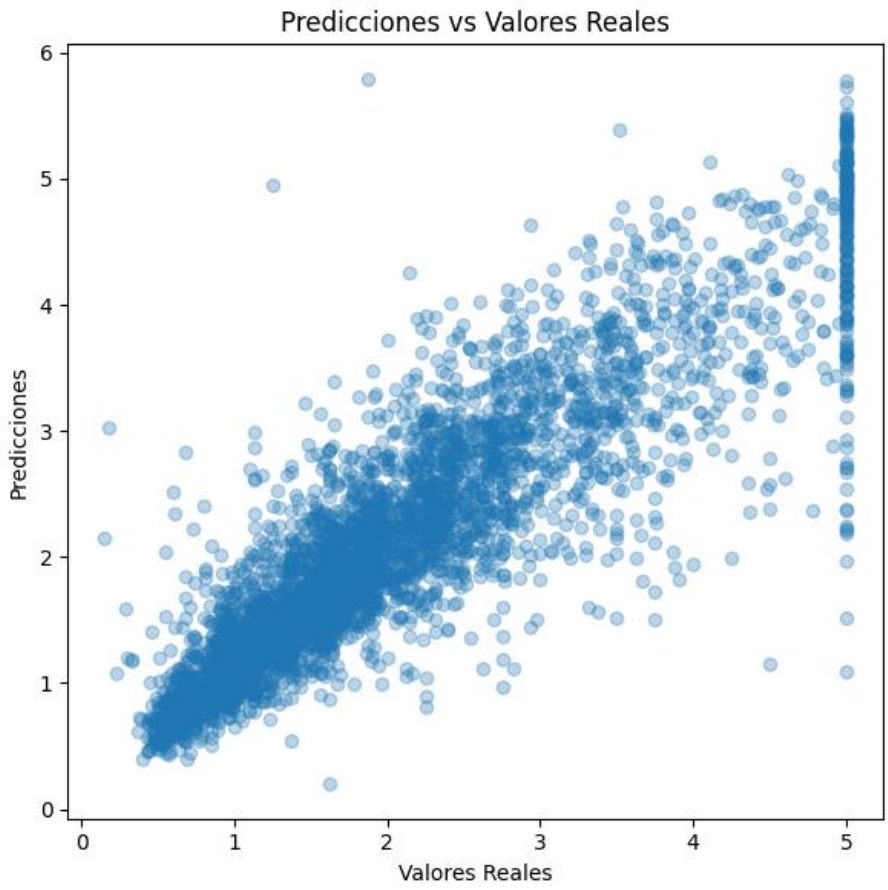

Metricas de regresión

```
MSE: 0.2870
MAE: 0.3733
RMSE: 0.5358
```

Predicciones nuevas

```
Observación 1: 0.5405
Observación 2: 1.4078
Observación 3: 4.6451
```

Conclusión

El presente laboratorio permitió diseñar e implementar redes neuronales fully connected para resolver un problema de clasificación multiclase y un problema de regresión utilizando la librería tensorflow.keras.

En el problema de clasificación de dígitos, el modelo alcanzó una accuracy del 97.78% en el conjunto de prueba, evidenciando una excelente capacidad de generalización. La matriz de confusión mostró que la mayoría de las predicciones se concentraron en la diagonal principal, con errores mínimos asociados principalmente a dígitos visualmente similares. Esto confirma que una arquitectura con dos capas ocultas es suficiente para capturar patrones espaciales aplanados cuando los datos son adecuadamente normalizados.

En el problema de regresión de precios de vivienda, el modelo obtuvo un RMSE de 0.5358, demostrando una capacidad predictiva adecuada. El uso de estandarización fue fundamental para garantizar estabilidad numérica y correcta convergencia del modelo. El gráfico de dispersión evidenció una correlación positiva clara entre valores reales y predicciones, confirmando la efectividad de la arquitectura profunda utilizada.

Se permitió comprender de manera práctica cómo las redes neuronales densas pueden adaptarse tanto a tareas de clasificación como de regresión, reforzando conceptos fundamentales de diseño, entrenamiento y evaluación de modelos de aprendizaje profundo.

Link del Github: AI/Lab3 at main · dils1809/AI